

標註更新 與評估計畫

現在怎麼做，完成後怎麼驗證

01

目前的標註

方法 · 資料卡 · 完成時間

02

接下來的評估

測試設計 · 差異 · 後續流程

讓模型看完物件，再填資料卡

01

11 個角度

同一物件，從不同方向觀看

02

同一回合

圖片分別放入同一回合

03


Gemma 判讀

一起理解外觀與物件屬性

04

JSON 資料卡

輸出欄位，交給程式檢查



同一張椅子 從不同角度看

示意選 3 張；實際輸入 11 張

11 張圖片分別輸入同一個對話回合，最後產生一份 JSON。

資料卡記錄什麼？

資料類別	主要欄位	真實椅子範例
是什麼	類別、語義類別、描述	chair ； 木製餐椅、粉紅座墊
什麼材質	materials	wood 、 fabric （木、布）
多大、多重	寬／深／高、體積、重量	45 × 45 × 90 cm ； 8 kg （估計）
通常放哪裡	天花板／牆／地板／物件上	onFloor = true （放在地板）

完整資料卡共 13 欄；尺寸、重量是模型估計，並非量測真值。

13 個主要欄位，整理成四類；尺寸與重量是模型估計。

有回答，還要檢查才能收錄

01

檢查資料卡

缺欄、格式、尺寸與重量範圍

02

帶著錯誤重答

初次＋最多兩次修正

03

收錄或隔離

合格收錄；失敗保留原因

項目	論文	目前做法
標註模型	GPT-4o	Gemma 4 12B • BF16
多視角輸入	11 張	11 張；提示與重試為本地選擇

先檢查，再收錄；最多三次作答，資源錯誤直接記為失敗。

標註進度與預估完成時間

54.54%

本輪已處理 25,089 / 46,004



成功	失敗隔離	待處理
25,063	26	20,915

只估標註處理；不含後續編碼、訓練與評估。

本輪已處理 54.54% ； 規劃於 9/9 上午完成標註佇列。

預計完成本輪標註

9/9 上午

規劃 09:00–12:00

近期約 11.7–11.9 件／分鐘
需持續運作且速度相近

用真實需求，比較三種找家具的方法

01

預訓練基準

ULIP2 特徵
本地平均融合

02

Stage 1

學習物件表徵
與多模態融合

03

Stage 2

場景訓練後的融合
本評估不輸入場景資訊

依輸入安排條件 $T / I / PC / T + I / T + PC / I + PC /$ 全部

T = 文字 I = 圖片 PC = 點雲；逐條件記錄題數

候選皆有 $T + I + PC$ ；三方法使用同一批資產

主評估問「是否符合需求」；三種方法使用同一題目、候選與正解。

一道需求，可以有好幾個合適答案

需求：找一張適合小餐桌、木質外觀的餐椅。

示意結果	怎麼解讀
8 個候選，其中 3 個可接受	正解依需求審核；不靠同一個 UID
可接受候選排在第 2、6、8 名	第一名不合適；前五名找到其中一個
Hit@1 = 0% ； Hit@5 = 100%	這一題前五名至少有一個合適選項
真正 Recall@5 = 1/3 = 33.3%	前五名找回全部可接受答案的三分之一

Hit：有沒有找到合適的

前五名只要有一個合適選項，就算命中。

Recall：合適的找回多少

有三個合適選項，找到一個＝找回三分之一。

主要看 Hit@1 / Hit@5：前 1 / 5 名是否至少有一個可接受選項。

新主評估與論文、舊診斷分開看

項目	論文或舊診斷	新主評估
問題與正解	論文完整 query / 正解配對未公開	使用者需求；每條件多個可接受候選
主要指標	論文稱 R@1 / R@5 ； 完整標註規則未知	Hit@1 / Hit@5 ； 輔助真正 Recall@k
P-only baseline	論文說 query / gallery 使用相同 PC embedding	本地 query=P ； gallery 固定融合 T+I+P
候選與資料	論文約 48K ； 確切候選清單未公開	先固定審核完整的候選池與題目分母
既有四十二組	同一資產 UID 的兩觀測辨識診斷	另列診斷；不是新主評估

這是已批准的本地需求檢索評估；不冒充作者 Table 1 原始協定。

先寫題、審答案、封存，最後才跑模型

01

準備需求與參考

ULIP-2 描述可作草稿
記錄原始文字、照片與
點雲

02

先審核合適答案

逐條件審完全部候選
來源 UID 不自動當正
解

03

凍結資料與模型

固定題目、答案與候選
池
核對 Stage 1 / 2 版
本

04

記錄逐題結果

主報 Hit，另報
Recall
未審完的資料不跑正式
分數

先完成並封存審核，再看模型排名；缺少標籤不能直接算不相關。

每題、每個模態條件，都先審完固定候選池；未審完就是待完成。

標註後，補齊資料、模型與需求考卷

01

整理標註與排除

對清有效資產、真正失敗與人工排除

02

編碼與固定切分

建立特徵、固定分組，另做資料預檢

03

訓練兩階段模型

Stage 1 / 候選庫核驗，再備妥 Stage 2

04

撰寫真實需求

獨立 query ID；選定可用參考線索

05

審核與封存答案

每條件完整 0 / 1 正解；先於模型排名

06

執行並報告結果

Hit@1 / Hit@5；另列 Recall 與舊診斷

完整題目與正解先封存，模型準備好後再另行執行主評估。